

Решение теоретических заданий
Вычислительная математика (пилотный курс)

Коцевич Андрей Витальевич, группа Б02-920

5 семестр, 2021

Содержание

1	A2	3
2	A3	6
3	A4	10

В папках А2 и А3 было 2 листика с домашним заданием. Я выбирал те, где задач больше.

1 А2

1. Пусть дана выборка точек y_i . Решите задачу МНК, моделируя данные постоянной величиной \tilde{y} , что отвечает минимизации функции потерь

$$\mathcal{L} = \sum_{i=1}^l (y_i - \tilde{y})^2 \rightarrow \min_{\tilde{y}} \quad (1)$$

Решение.

$$\frac{\partial \mathcal{L}}{\partial \tilde{y}} = -2 \sum_{i=1}^l (y_i - \tilde{y}) = 0 \quad (2)$$

$$\sum_{i=1}^l y_i - l\tilde{y} = 0 \quad (3)$$

$$\boxed{\tilde{y} = \frac{\sum_{i=1}^l y_i}{l} = \bar{y}} \quad (4)$$

2. Покажите, что прямая, построенная по методу МНК, всегда проходит через точку (\bar{x}, \bar{y}) , где \bar{x} и \bar{y} – выборочные средние. Обобщите на случай многомерной регрессии.

Решение.

Линейная регрессия:

$$g_w(x) = xw + b \quad (5)$$

Формула МНК:

$$b = \bar{y} - w\bar{x} \quad (6)$$

$$g_w(x) = xw + \bar{y} - w\bar{x} = w(x - \bar{x}) + \bar{y} \rightarrow \boxed{g_w(\bar{x}) = \bar{y}} \quad (7)$$

По аналогии, в случае многомерной регрессии гиперплоскость, построенная по методу МНК, всегда проходит через точку $(\bar{x}_1, \dots, \bar{x}_n, \bar{y}_1, \dots, \bar{y}_m)$.

5. На лекции обсуждалось, что метод наименьших квадратов – это способ поставить задачу о решении переопределенной системы $Xw = y$, которая имеет явный ответ, выражающийся через левую псевдообратную матрицу для X . Для недоопределенной системы $Xw = y$ (имеющей бесконечно много решений) можно поставить задачу о поиске решения с минимальной l_2 -нормой весов $\|w\|^2 = w^T w$. Решите такую задачу и покажите, что ответ выражается через правую псевдообратную матрицу для X . Считайте, что прямоугольная матрица X имеет полный ранг (максимально возможный).

Решение. Для поиска решения с минимальной l_2 -нормой весов $\|w\|^2 = w^T w$ (условного экстремума) воспользуемся методом множителей Лагранжа:

$$\mathcal{L} = \lambda^T (Xw - y) + w^T w \rightarrow \min_w |_{w \rightarrow \min} \quad (8)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = (Xw - y)^T = 0 \rightarrow y = Xw \quad (9)$$

$$\frac{\partial \mathcal{L}}{\partial w} = \lambda^T X + 2w^T = 0 \rightarrow w^T = -\frac{1}{2}\lambda^T X \quad (10)$$

Транспонируем левую и правую части:

$$w = -\frac{1}{2}X^T \lambda \quad (11)$$

$$y = Xw = -\frac{1}{2}XX^T \lambda \rightarrow \lambda = -2(XX^T)^{-1}y \quad (12)$$

$$\lambda = -2(X^{-1})^T X^{-1}y = -2(XX^T)^{-1}y \quad (13)$$

Отсюда получаем

$$\boxed{w = X^T(XX^T)^{-1}y} \quad (14)$$

где $R = X^T(XX^T)^{-1}$ – правая псевдообратная матрица.

7. На лекции обсуждался учет влияния систематической погрешности путем усреднения решения задачи МНК по гауссовому нормальному распределению для y -координат точек выборки: $\tilde{y}_i \sim \mathcal{N}(y_i, s^2)$, где погрешность по оси ординат считалась равной s . Обобщите этот вывод на случай, когда каждая точка имеет свою y -погрешность s_i . Для этого проведите усреднение по многомерному нормальному распределению для \tilde{y}_i с произвольной симметричной матрицей ковариации A^1 :

$$\tilde{y} \sim \frac{1}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \exp \left(-\frac{(\tilde{y} - y)^T A^{-1}(\tilde{y} - y)}{2} \right), \quad (15)$$

где $y = (y_1, \dots, y_l)^T$, а $\tilde{y} = (\tilde{y}_1, \dots, \tilde{y}_l)^T$.

1. Покажите, что распределение правильно нормированно. Указание: Выполните замену координат $\tilde{y} - y = Sz$, где матрица S диагонализует A .
2. Вычислите неприводимые парные корреляторы $\ll \tilde{y}_i \tilde{y}_j \gg$, усредняя по распределению. Указание: Сделайте замену $\tilde{y} - y = Y$. Для вычисления гауссового интеграла с предэкспонентой вычислите интеграл $\int d^l Y \exp(-Y^T A^{-1} Y / 2 + J^T Y)$ и выполните дифференцирование по параметрам J_i (компоненты вектора J).
3. Оцените погрешности параметров модели w_α , следуя вычислению, приведенному на лекции, и используя корреляторы, полученные в предыдущем пункте.
4. Запишите решение в частном случае диагональной матрицы $A = \text{diag}(A_1, \dots, A_l)$. Как следует выбирать величины A_i для моделирования y -погрешности i -ой точки, равной s_i ?

Решение.

1. Поскольку матрица A^{-1} симметрична, то $\exists S : S^T A^{-1} S = E$ и $\det S = \sqrt{\det A}$. Выполним замену координат $\tilde{y} - y = Sz$.

$$\int \tilde{y} d^l \tilde{y} = \frac{\det S}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \int d^l z \exp \left(-\frac{zz^T}{2} \right) = \frac{1}{(2\pi)^{\frac{l}{2}}} (2\pi)^{\frac{l}{2}} = 1 \quad (16)$$

Распределение правильно нормированно.

2. Сделаем замену $\tilde{y} - y = Y$.

$$\ll \tilde{y}_i \tilde{y}_j \gg = \langle (\tilde{y}_i - y_i)(\tilde{y}_j - y_j) \rangle = \langle Y_i Y_j \rangle \quad (17)$$

Обозначим интеграл с током

$$\begin{aligned} I_J &= \frac{1}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \int d^l Y \exp \left(-\frac{Y^T A^{-1} Y}{2} + J^T Y \right) = \\ &= \frac{1}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \int d^l Y \exp \left(\frac{(Y - AJ)^T A^{-1} (Y - AJ)}{2} + \frac{(AJ)^T A^{-1} AJ}{2} \right) = \\ &= \exp \left(\frac{J^T A^{-1} J}{2} \right) = \exp \left(\frac{J^T A J}{2} \right), \end{aligned} \quad (18)$$

поскольку A – симметричная.

$$\frac{\partial I_J}{\partial J_i} \Big|_{J=0} = \frac{1}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \int d^l Y Y_i \exp \left(-\frac{Y^T A^{-1} Y}{2} \right) = \langle Y_i \rangle = 0 \quad (19)$$

$$\frac{\partial^2 I_J}{\partial J_i \partial J_j} \Big|_{J=0} = \frac{1}{(2\pi)^{\frac{l}{2}} \sqrt{\det A}} \int d^l Y Y_i Y_j \exp \left(-\frac{Y^T A^{-1} Y}{2} \right) = \langle Y_i Y_j \rangle \quad (20)$$

$$\frac{\partial^2 I_J}{\partial J_i \partial J_j} \Big|_{J=0} = A_{ij} \quad (21)$$

Таким образом, неприводимые парные корреляторы

$$\boxed{\ll \tilde{y}_i \tilde{y}_j \gg = A_{ij}} \quad (22)$$

3.

$$w = Qy, \quad Q = (X^T X)^{-1} X^T \quad (23)$$

В индексных обозначениях:

$$w_\alpha = Q_{\alpha i} y_i, \quad \tilde{w}_\alpha = Q_{\alpha i} \tilde{y}_i \quad (24)$$

$$\text{var} \tilde{w}_\alpha = \ll \tilde{w}_\alpha \tilde{w}_\alpha \gg = Q_{\alpha i} Q_{\alpha j} \ll \tilde{y}_i \tilde{y}_j \gg = Q_{\alpha i} Q_{\alpha j} A_{ij} \quad (25)$$

$$\boxed{\text{var} \tilde{w}_\alpha = (Q A Q^T)_{\alpha\alpha}} \quad (26)$$

4. Из предыдущего пункта:

$$\boxed{\text{var} \tilde{w}_\alpha = \sum_{i=1}^n Q_{\alpha i}^2 A_{ii}} \quad (27)$$

Для моделирования y -погрешности i -ой точки, равной s_i , нужно выбрать A_i :

$$\boxed{A_i = \ll \tilde{y}_i \tilde{y}_i \gg = s_i^2} \quad (28)$$

Необязательное дополнение. Случай линейной регрессии:

$$X = \begin{pmatrix} x_1 & 1 \\ \dots & \dots \\ x_l & 1 \end{pmatrix}, \quad Q = (X^T X)^{-1} X^T = \frac{1}{l(\text{var } x)^2} \begin{pmatrix} x_1 - \bar{x} & \dots & x_l - \bar{x} \\ \bar{x}^2 - \bar{x}x_1 & \dots & \bar{x}^2 - \bar{x}x_l \end{pmatrix} \quad (29)$$

$$\text{var } \tilde{w}_1 = \frac{1}{l(\text{var } x)^2} \left(\overline{x^2 A^2} - 2\bar{x} \overline{x A^2} + \bar{x}^2 \overline{A^2} \right), \quad \text{var } \tilde{w}_0 = \frac{1}{l(\text{var } x)^2} \left(\overline{x^2 A^2} - 2\bar{x} \overline{x A^2} + \bar{x}^2 \overline{A^2} \right)$$

$$\boxed{\text{var } \tilde{w}_1 = \frac{1}{l(\text{var } x)^2} \left(\overline{x^2 s^2} - 2\bar{x} \overline{x s^2} + \bar{x}^2 \overline{s^2} \right), \quad \text{var } \tilde{w}_0 = \frac{1}{l(\text{var } x)^2} \left(\overline{x^2 s^2} - 2\bar{x} \overline{x s^2} + \bar{x}^2 \overline{s^2} \right)} \quad (30)$$

При $s_i = s = \text{const}$ получаем формулы с лекции:

$$\text{var } \tilde{w}_1 = \frac{s^2}{l \text{var } x}, \quad \text{var } \tilde{w}_0 = \frac{s^2 \bar{x}^2}{l \text{var } x} \quad (31)$$

2 A3

1. Пусть дана выборка точек на прямой $\{x_i\}$. Максимизируйте правдоподобие (или его логарифм) в гауссовой вероятностной модели:

$$\prod_i p(x_i) \rightarrow \max_{\mu, \sigma}, \quad p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x - \mu)^2}{2\sigma^2} \right) \quad (32)$$

Решение. Пусть при измерении величины μ мы получили выборку $\{x_i\}$. Плотность вероятности того, что величина μ примет значение x_i :

$$p(x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (33)$$

Плотность вероятности того, что величина μ примет значения x_1, \dots, x_n :

$$p(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^{\frac{n}{2}} \exp \left(-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (34)$$

Логарифм правдоподобия:

$$\log p(x_1, \dots, x_n) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \quad (35)$$

Условия максимума правдоподобия:

$$\frac{\partial(\log p(x_1, \dots, x_n))}{\partial \mu} = \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} = 0 \rightarrow \boxed{\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}_i} \quad (36)$$

$$\frac{\partial(\log p(x_1, \dots, x_n))}{\partial \sigma} = -\frac{n}{\sigma} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^3} = 0 \rightarrow \hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \quad (37)$$

$$\boxed{\hat{\sigma}^2 = \text{var } x} \quad (38)$$

2. Количество срабатываний счетчика Гейгера за минуту n подчиняется распределению Пуассона:

$$P_\lambda(n) = \frac{\lambda^n}{n!} e^{-\lambda} \quad (39)$$

1. В ходе эксперимента счетчик Гейгера сработал за минуту m раз. С помощью теоремы Байеса определите апостериорное распределение на λ . Указание: априорную плотность вероятности λ можно считать постоянной (так как мы изначально ничего не знаем про λ).
2. Эксперимент повторили ещё раз, в этот раз счетчик Гейгера сработал за минуту m' раз. Как обновилось апостериорное распределение на λ ?

Решение.

1. $P(\lambda) = P_0 = \text{const}$ – априорное распределение, $P(\lambda|m)$ – апостериорное. По теореме Байеса:

$$P(\lambda|m) = \frac{P(m|\lambda)P(\lambda)}{P(m)} = \frac{P(m|\lambda)P(\lambda)}{\int d\lambda P(m|\lambda)P(\lambda)} = \frac{P_\lambda(m)}{\int_0^\infty d\lambda P_\lambda(m)} = P_\lambda(m) \quad (40)$$

$$\boxed{P(\lambda|m) = \frac{\lambda^m}{m!} e^{-\lambda}} \quad (41)$$

2. Теперь $P(\lambda) = P(\lambda|m) = P_\lambda(m)$ – априорное распределение, $P(\lambda|m, m')$ – апостериорное. По теореме Байеса:

$$P(\lambda|m, m') = \frac{P(m'|\lambda)P(\lambda)}{P(m')} = \frac{P(m'|\lambda)P(\lambda)}{\int d\lambda P(m'|\lambda)P(\lambda)} = \frac{P_\lambda(m')P_\lambda(m)}{\int_0^\infty d\lambda P_\lambda(m')P_\lambda(m)} \quad (42)$$

$$\boxed{P(\lambda|m, m') = \frac{2^{1+m+m'} \lambda^{m+m'}}{(m+m')!} e^{-2\lambda}} \quad (43)$$

3. Ультрочувствительный тест от коронавируса ошибается в 1% случаев (как в одну, так и в другую сторону). В данный момент в популяциидоля заболевших 10^{-5} . Петя получил положительный тест на коронавирус. С какой вероятностью он действительно болеет коронавирусом?

Решение. Обозначим через событие A – болезнь коронавирусом, через B – положительный результат теста. Тогда

$$P(A) = 10^{-5}, \quad P(B|A) = 0,99, \quad P(B|\neg A) = 0,01 \quad (44)$$

По теореме Байеса:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|\neg A)P(\neg A)} \quad (45)$$

$$P(A|B) = \frac{0,99 \cdot 10^{-5}}{0,99 \cdot 10^{-5} + 0,01 \cdot (1 - 10^{-5})} = 9,89 \cdot 10^{-4} \quad (46)$$

Как видно, Пете следует сделать повторный тест.

4. Пусть имеется априорное распределение на вектор \vec{x} , задаваемое матрицей A :

$$p_0(\vec{x}) = \frac{1}{Z} e^{-\frac{\vec{x}^T A \vec{x}}{2}} \quad (47)$$

Было произведено измерение величин \vec{x} , которое дало значение \vec{x}_1 . Найдите апостериорное распределение на \vec{x} .

Решение.

Распишем априорное распределение на вектор \vec{x} :

$$p_0(\vec{x}) = \frac{1}{Z} e^{-\frac{\sum_{i,j=1}^n x_i A_{ij} x_j}{2}} = \frac{1}{Z} \prod_{i,j=1}^n e^{-\frac{x_i A_{ij} x_j}{2}} \quad (48)$$

$P(A) = P_0 = \text{const}$ – априорное распределение A , $P(A|\vec{x}_1)$ – апостериорное. По теореме Байеса:

$$P(A|\vec{x}_1) = \frac{P(\vec{x}_1|A)P(A)}{P(\vec{x}_1)} = \frac{P(\vec{x}_1|A)P(A)}{\int_{-\infty}^{\infty} P(\vec{x}_1|A)P(A)dA} = \frac{\prod_{i,j=1}^n e^{-\frac{x_{1i}A_{ij}x_{1j}}{2}} P_0}{\prod_{i,j=1}^n \int_0^{\infty} e^{-\frac{x_{1i}A_{ij}x_{1j}}{2}} P_0 dA_{ij}} \quad (49)$$

$$P(A|\vec{x}_1) = \frac{\prod_{i,j=1}^n e^{-\frac{x_{1i}A_{ij}x_{1j}}{2}}}{\prod_{i,j=1}^n \frac{2}{x_{1i}x_{1j}}} = \frac{\prod_{i=1}^n x_{1i}^{n^2}}{2^{n^2}} e^{-\frac{\sum_{i,j=1}^n x_{1i}A_{ij}x_{1j}}{2}} \quad (50)$$

Апостериорное распределение на \vec{x} :

$$P(\vec{x}) = \int_0^{\infty} P(\vec{x}|A)P(A|\vec{x}_1)dA = \frac{\prod_{i=1}^n x_{1i}^{n^2}}{2^{n^2} Z} \prod_{i,j=1}^n \int_0^{\infty} e^{-\frac{x_i A_{ij} x_j}{2}} e^{-\frac{x_{1i} A_{ij} x_{1j}}{2}} dA_{ij} \quad (51)$$

$$P(\vec{x}) = \frac{\prod_{i=1}^n x_{1i}^{n^2}}{Z} \prod_{i,j=1}^n \frac{1}{x_i x_j + x_{1i} x_{1j}} \quad (52)$$

7. Покажите, что задача минимизации квадратичной функции потерь с дополнительным ограничением (лассо Тибширани):

$$\mathcal{L} = \|Xw - y\|^2 \rightarrow \min_w, \quad \sum_{\alpha} |w_{\alpha}| < C \quad (53)$$

эквивалентна L_1 -регуляризации. *Указание:* можно воспользоваться условиями Каруша-Куна-Таккера (обобщение метода Лагранжа).

Доказательство. Для исследования дополнительного ограничения в задаче минимизации квадратичной функции потерь (лассо Тибширани) воспользуемся множителем Лагранжа μ :

$$\mathcal{L}' = \|Xw - y\|^2 + \mu \left(\sum_{\alpha} |w_{\alpha}| - C \right) \quad (54)$$

Достаточные условия Каруша - Куна - Таккера:

$$\begin{cases} \min_w \mathcal{L}'(w) = \mathcal{L}'(\hat{w}), \\ \mu \left(\sum_{\alpha} |\hat{w}_{\alpha}| - C \right) = 0, \\ \mu > 0 \end{cases} \quad (55)$$

L_1 -регуляризация:

$$\mathcal{L}'' = \|Xw - y\|^2 + \mu \sum_{\alpha} |w_{\alpha}| \rightarrow \min_w \quad (56)$$

Решение задачи минимизации удовлетворяет L_1 -регуляризации, поскольку при выполнении условий Каруша - Куна - Таккера при $w_a = \hat{w}_a$: $\mathcal{L}'' = \mu C \rightarrow$ достигает минимума. Обратное, устремление к минимуму \mathcal{L}'' при L_1 -регуляризации приводит к условиям Каруша-Куна-Таккера. \square

8.* Bias-Variance decomposition

Воспользуемся вероятностной моделью данных, в которой предполагается, что каждый элемент выборки не зависимо от других поступает из распределения $p(x, y)$. Тогда вероятность получить какой-то конкретный набор данных $(X_l, y_l) = (x_1, \dots, x_l; y_1, \dots, y_l)$ в обучающей выборке равна $p(X_l, y_l) = \prod_{i=1}^l p(x_i, y_i)$. В дальнейшем будем обозначать как (x, y) элемент тестовой выборки, который не входит в (X_l, y_l) .

В выбранной модели $\check{y} = g_{\theta}(x)$ параметры θ определяются с помощью фиттирования по обучающей выборке: $\theta = \theta(X_l, y_l)$, поэтому \check{y} зависит от x , X_l и y_l . Тогда формальное выражение для функции потерь (соответствующее пределу бесконечной большой тестовой выборки) можно записать как

$$L = \mathbb{E}_{X_l, y_l} [\mathbb{E}_{x, y} (y - \check{y})^2] \quad (57)$$

В этом выражении квадратичная функция потерь усредняется по элементу тестовой выборки (x, y) и по обучающей выборке (X_l, y_l) .

Покажите, что справедливо разложение этой величины на шум, смещение и разброс:

$$L = \mathbb{E}_{x, y} (y - \mathbb{E}(y|x))^2 + \mathbb{E}_{x, y} (\mathbb{E}_{X_l, y_l}(\check{y}) - \mathbb{E}(y|x))^2 + \mathbb{E}_{x, y} (\mathbb{E}_{X_l, y_l}(\check{y} - \mathbb{E}_{X_l, y_l}(\check{y}))^2) \quad (58)$$

где $\mathbb{E}_{x, y} (y - \mathbb{E}(y|x))^2$ – noise, $\mathbb{E}_{x, y} (\mathbb{E}_{X_l, y_l}(\check{y}) - \mathbb{E}(y|x))^2$ – bias, $\mathbb{E}_{x, y} (\mathbb{E}_{X_l, y_l}(\check{y} - \mathbb{E}_{X_l, y_l}(\check{y}))^2)$ – variance. *Указание:* сначала покажите, что

$$\mathbb{E}_{x, y} (y - \check{y})^2 = \mathbb{E}_{x, y} (y - \mathbb{E}(y|x))^2 + \mathbb{E}_{x, y} (\mathbb{E}(y|x) - \check{y})^2 \quad (59)$$

Доказательство. Пусть $y = f(x) + \varepsilon$ – функция с шумом, где шум ε имеет $\mathbb{E}(\varepsilon) = 0$ и $\text{var } \varepsilon = \mathbb{E}_{x, y} (y - \mathbb{E}(y|x))^2$.

$$\mathbb{E}_{x, y} y = \mathbb{E}_{x, y} (f(x) + \varepsilon) = \mathbb{E}_{x, y} (f(x)) = f(x) \quad (60)$$

$$\text{var } y = \mathbb{E}_{x, y} (y - \mathbb{E}_{x, y}(y))^2 = \mathbb{E}_{x, y} (y - f)^2 = \mathbb{E}_{x, y} \varepsilon^2 = (\mathbb{E}_{x, y} \varepsilon)^2 + \text{var } \varepsilon = \text{var } \varepsilon \quad (61)$$

Поскольку ε и f независимы, то запишем

$$\mathbb{E}_{x,y}(y - \check{y})^2 = \mathbb{E}_{x,y}(y^2 + \check{y}^2 - 2y\check{y})^2 = \text{var } y + \mathbb{E}_{x,y}y^2 + \text{var}\check{f} + \mathbb{E}_{x,y}\check{f}^2 - 2f\mathbb{E}_{x,y}\check{y} \quad (62)$$

$$\mathbb{E}_{x,y}(y - \check{y})^2 = \text{var } y + \text{var}\check{f} + (f^2 - 2f\mathbb{E}_{x,y}\check{y} + \mathbb{E}_{x,y}\check{y}^2) = \text{var } y + \text{var}\check{y} + (f - \mathbb{E}_{x,y}\check{y})^2 \quad (63)$$

где 1 слагаемое – прообраз noise, второе – variance, третье – bias. Усредняя также по обучающей выборке, получаем требуемое. \square

3 A4

2. Пусть X – матрица объект-признак (размерность $l \times F$), для которой сингулярное разложение имеет вид $X = V\sqrt{\Lambda}U^T$. После понижения размерности данных с помощью метода главных компонент, в диагональной матрице $\Lambda = \text{diag}\{\lambda_1 \geq \dots \geq \lambda_F\}$ оставляются только \tilde{F} наибольших сингулярных чисел: $\tilde{\Lambda} = \text{diag}\{\lambda_1 \geq \dots \geq \lambda_{\tilde{F}}\}$. При этом данные, как правило, можно восстановить только с некоторой ошибкой: $\tilde{X} = V\sqrt{\tilde{\Lambda}}U^T \neq X$. Покажите, что L_2 норма ошибки выражается через сумму по оставшимся сингулярным числам:

$$\frac{1}{l} \|X - \tilde{X}\|^2 = \sum_{i=\tilde{F}+1}^F \lambda_i \quad (64)$$

Доказательство.

$$X = V\sqrt{\Lambda}U^T, \quad \tilde{X} = V\sqrt{\tilde{\Lambda}}U^T \quad (65)$$

$$X - \tilde{X} = V \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right) U^T \quad (66)$$

$$\begin{aligned} \|X - \tilde{X}\|^2 &= \text{Tr}((X - \tilde{X})(X - \tilde{X})^T) = \text{Tr} \left(V \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right) U^T \left(V \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right) U^T \right)^T \right) = \\ &= \text{Tr} \left(V \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right) U^T U \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right)^T V^T \right) = \text{Tr} \left(\left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right) \left(\sqrt{\Lambda} - \sqrt{\tilde{\Lambda}} \right)^T \right) \end{aligned} \quad (67)$$

$$\boxed{\|X - \tilde{X}\|^2 = \sum_{i=\tilde{F}+1}^F \lambda_i} \quad (68)$$

\square

3. Покажите, что сингулярный вектор матрицы X , отвечающий наибольшему сингулярному числу, является решением задачи

$$\vec{u} = \text{argmax}_{\|\vec{u}\|=1} (X\vec{u})^2 \quad (69)$$

где подразумевается матричное умножение X на \vec{u} .

Доказательство. Сингулярное разложение:

$$X = V\sqrt{\Lambda}U^T, \quad \sqrt{\Lambda} = \text{diag}\{\lambda_1 \geq \dots \geq \lambda_F\} \quad (70)$$

$$XU = V\sqrt{\Lambda} \rightarrow X\vec{u} = \sqrt{\lambda}\vec{v} \quad (71)$$

Как видно, максимум $(X\vec{u})^2$ достигается при максимальном $\lambda = \lambda_1$, этому сингулярному числу соответствует вектор \vec{u} , удовлетворяющий

$$\vec{u} = \operatorname{argmax}_{\|\vec{u}\|=1} (X\vec{u})^2 \quad (72)$$

□

4. Пусть дан набор точек на плоскости (x_i, y_i) , для которых выборочные средние x_i и y_i равны нулю. Покажите, что сингулярный вектор для матрицы объект-признак, отвечающий наибольшему сингулярному числу, задаёт прямую a (проходящую через начало координат), которая является решением следующей задачи оптимизации:

$$L' = \sum_{i=1}^N \operatorname{distance}^2[(x_i, y_i); a] \rightarrow \min_a \quad (73)$$

где $\operatorname{distance}[(x_i, y_i); a]$ – расстояние от точки (x_i, y_i) до прямой a (равное длине перпендикуляра).

Обратите внимание, что такая задача отличается от задачи МНК, в которой расстояние от точки до аппроксимирующей прямой вычисляется не по перпендикуляру, а вдоль оси y , отвечающей целевой переменной.

Доказательство. По теореме Пифагора:

$$\sum_{i=1}^N \operatorname{distance}^2[(x_i, y_i); a] = \sum_{i=1}^N (r_i^2 - (\vec{r}_i, \vec{a})^2) \rightarrow \min_a \quad (74)$$

где \vec{r}_i – радиус-вектор i -й точки. $\sum_{i=1}^N r_i^2$ фиксирована и не зависит от направления прямой, поэтому

$$\sum_{i=1}^N (\vec{r}_i, \vec{a})^2 = (X\vec{a})^T (X\vec{a}) = (X\vec{a})^2 \rightarrow \max_a \quad (75)$$

где столбцы матрицы X – векторы \vec{r}_i . Из предыдущей задачи известно, что максимум достигается на сингулярном векторе \vec{a} , отвечающем наибольшему сингулярному числу. □

5. Пусть дан набор из N точек в трёхмерном пространстве $X_{i\alpha}, i \in \{1, \dots, N\}, \alpha \in \{1, 2, 3\}$. Покажите, что задача нахождения сингулярных чисел матрицы X эквивалентна нахождению *главных моментов инерции* твёрдого тела, составленного из набора точечных масс, расположенных в точках (X_{i1}, X_{i2}, X_{i3}) (можно представлять себе, что точечные массы соединены между собой невесомыми и абсолютно жёсткими стержнями).

Доказательство. Распишем X :

$$X = \begin{pmatrix} x_1 & y_1 & z_1 \\ \dots & \dots & \dots \\ x_l & y_l & z_l \end{pmatrix} \quad (76)$$

$$X^T X \equiv \hat{\text{Cov}} X = \begin{pmatrix} \sum_i x_i^2 & \sum_{i,j} x_i y_j & \sum_{i,j} x_i z_j \\ \sum_{i,j} x_i y_j & \sum_i y_i^2 & \sum_{i,j} y_i z_j \\ \sum_{i,j} x_i z_j & \sum_{i,j} y_i z_j & \sum_i z_i^2 \end{pmatrix} \quad (77)$$

Момент инерции

$$\hat{I} = \begin{pmatrix} \sum_i y_i^2 + z_i^2 & -\sum_{i,j} x_i y_j & -\sum_{i,j} x_i z_j \\ -\sum_{i,j} x_i y_j & \sum_i x_i^2 + z_i^2 & -\sum_{i,j} y_i z_j \\ -\sum_{i,j} x_i z_j & -\sum_{i,j} y_i z_j & \sum_i x_i^2 + y_i^2 \end{pmatrix} \quad (78)$$

Матрицы $X^T X$ и I диагонализуются совместно. В системе координат, где они обе диагональные, $\sum_{i,j} x_i y_j = 0$. Собственные числа $X^T X$ (которые являются сингулярными числами X) и главные моменты инерции совпадают. \square